Validación de Datos: Del Laboratorio al Pipeline

Facundo Sanchez
Estudiante de Física Médica (UNSAM) & Data Engineering

13 de octubre de 2026

Contexto Real

Un laboratorio registra mediciones, pero algunas son incorrectas. Antes de calcular estadísticas, necesitamos distinguir los datos confiables de los defectuosos. Un pipeline puede automatizar errores, y un modelo estadístico puede dar resultados engañosos si recibe datos inválidos.

1. El Problema

Imaginemos que recibimos una lista de mediciones de un instrumento de laboratorio:

```
mediciones = [1.2, 1.4, 1.3, None, 1.5, .error", 1.1, 1000, float("nan"),
float(inf")]
```

2. La Solución: Clasificar antes de rechazar

En lugar de simplemente descartar lo que "no sirve", clasificamos cada error para entender qué está pasando.

Concepto Clave: `math.isfinite()`

En Python existen valores numéricos especiales como `float("nan")` (Not a Number) e `float(inf")` (infinito). La función `math.isfinite()` devuelve `True` solo si el número es finito, excluyendo estos casos especiales que romperían cualquier cálculo.

3. Código de Implementación

```
import math
MINIMO = -5.0 MAXIMO = 5.0
def clasificar_medicion(valor) : if isinstance(valor, bool) or not isinstance(valor, (int, float)) :
return "error de formato" if not math.isfinite(valor) : return "nmero no finito" if not MINIMO <=
valor <= MAXIMO : return "fuera de rango" return "vlida"
```

4. Resultados del Informe de Calidad

Al procesar la lista, el sistema genera el siguiente reporte:

- **Total recibidas:** 10

- **Válidas:** 5 (Promedio: 1.3)
- **Rechazadas:** 5
  - Error de formato: 2 (`None`, `.erroror"`)
  - Número no finito: 2 (`NaN`, `Inf`)
  - Fuera de rango: 1 (`1000`)

Documento generado para el portfolio de Facundo Sanchez.