Validación de Datos: Del Laboratorio al Pipeline

Facundo Sanchez
Estudiante de Física Médica (UNSAM) & Data Engineering

13 de octubre de 2026

Contexto Real

Un laboratorio registra mediciones, pero algunas son incorrectas. Antes de calcular estadísticas, necesitamos distinguir los datos confiables de los defectuosos. Un pipeline puede automatizar errores, y un modelo estadístico puede dar resultados engañosos si recibe datos inválidos.

1. El Problema

Imaginemos que recibimos una lista de mediciones de un instrumento de laboratorio. Notemos que incluye datos correctos, errores de formato (`None`, strings) y valores numéricos especiales inválidos:

```
mediciones = [1.2, 1.4, 1.3, None, 1.5, "error", 1.1, 1000,
              float("nan"), float("inf")]
```

2. La Solución: Clasificar antes de rechazar

En lugar de simplemente descartar lo que "no sirve", clasificamos cada error para entender qué está pasando y poder auditar el pipeline.

Concepto Clave: `math.isfinite()`

En Python existen valores numéricos especiales como `float("nan")` (Not a Number) e `float(ïnf")` (infinito). La función `math.isfinite()` devuelve `True` **solo** si el número es finito, excluyendo estos casos especiales que romperían cualquier cálculo estadístico posterior.

3. Código de Implementación

A continuación, la función principal de validación. Notar el uso de validaciones encadenadas para clasificar el tipo exacto de error:

```
1 import math
2
3 MINIMO = -5.0
4 MAXIMO = 5.0
5
6 def clasificar_medicion(valor):
7     # 1. Comprobar el formato (rechaza None, strings, etc.)
8     if isinstance(valor, bool) or not isinstance(valor, (int, float)):
9         return "error de formato"
```

```
10
11      # 2. Comprobar si es finito (rechaza NaN e Infinito)
12      if not math.isfinite(valor):
13          return "numero no finito"
14
15      # 3. Comprobar el rango permitido por el instrumento
16      if not MINIMO <= valor <= MAXIMO:
17          return "fuera de rango"
18
19      return "valida"
```

Nota: En el código fuente usamos palabras sin tildes en los `return` *para mantener la compatibilidad estandarizada en pipelines de datos, aunque el reporte final al usuario sí las incluye.*

4. Resultados del Informe de Calidad

Al procesar la lista original, el sistema genera el siguiente reporte automatizado:

- **Total recibidas:** 10
- **Válidas:** 5 (Promedio calculado: 1.3)
- **Rechazadas:** 5
  - **Error de formato:** 2 (`None`, `.erro r"`)
  - **Número no finito:** 2 (`NaN`, `Inf`)
  - **Fuera de rango:** 1 (`1000`)